

ЛАБОРАТОРНА РОБОТА II ІАД

ВСТУП ДО NATURAL LANGUAGE PROCESSING (NLP)

Мета роботи: Познайомитися з основними поняттями, методами та підходами у сфері обробки природної мови (NLP). Провести порівняльний аналіз популярних алгоритмів та інструментів, а також підготувати презентацію на цю тему.

ВИКОНАЛА
ЙОВХИМИЦЬ ДІАНА

TCIM3

- Теоретичне дослідження ○
- Ключові моделі для NLP ○
- Порівняльний аналіз ○
- методів векторизації тексту
- Огляд інструментів для NLP ○

- Visual Style ○
- Timeline ○
- Metrics of Success ○
- Contact ○

ТЕОРЕТИЧНЕ ДОСЛІДЖЕННЯ

ОСНОВНІ ЕТАПИ NLP

ТОКЕНІЗАЦІЯ

Токенізація - це перший і один із найважливіших етапів у системах NLP.

Вона полягає у розбитті тексту на дрібніші одиниці — токени, які можуть бути словами, реченнями або частинами слів. Коректна токенізація визначає якість подальших етапів обробки тексту.

Види токенізації:

1. Токенізація на слова: розділення тексту на окремі слова
2. Токенізація на речення: визначення меж речень у тексті
3. Субсловна токенізація: розбиття складних слів на частини

Застосування: всі системи NLP починають з токенізації, це фундаментальний етап для подальшої обробки.

ТЕОРЕТИЧНЕ ДОСЛІДЖЕННЯ

ОСНОВНІ ЕТАПИ NLP

ЛЕММАТИЗАЦІЯ ТА СТЕМІНГ

Ці методи використовуються для приведення слів до їх базової форми.

Стемінг:

1. Відсікання закінчень для отримання основи слова
2. Швидкий, але неточний метод
3. Приклади: "бігаючи" → "біга", "читання" → "чит"
4. Алгоритми: Porter Stemmer, Snowball Stemmer

Лемматизація:

1. Приведення слова до його базової форми (леми) з урахуванням контексту
2. Повільніший, але точніший метод
3. Вимагає знання морфології мови
4. Приклади: "кращому" → "хороший", "бігав" → "бігати"

Відмінності між стемінгом та лемматизацією:

1. Стемінг працює на рівні окремих слів без контексту
2. Лемматизація враховує частину мови та контекст

ТЕОРЕТИЧНЕ ДОСЛІДЖЕННЯ

ОСНОВНІ ЕТАПИ NLP

ВЕКТОРИЗАЦІЯ ТЕКСТУ

Векторизація тексту -це перетворення тексту в числові вектори для подальшої обробки ML-алгоритмами.

Bag of Words (BOW):

- 1.Представлення тексту як мішка слів без урахування порядку
- 2.Кожен документ - вектор, де кожен елемент відповідає кількості входжень слова
- 3.Простий, але втрачає контекст та порядок слів

TF-IDF (Term Frequency-Inverse Document Frequency):

- 1.Покращена версія BOW, що враховує важливість слів
- 2.TF (Term Frequency) - частота слова в документі
- 3.IDF (Inverse Document Frequency) - обернена частота документу
- 4.Зменшує вагу загальних слів, підвищує вагу унікальних

Word Embeddings:

- 1.Векторні представлення слів у багатовимірному просторі
- 2.Зберігають семантичні та синтаксичні зв'язки
- 3.Методи: Word2Vec, GloVe, FastText

ТЕОРЕТИЧНЕ ДОСЛІДЖЕННЯ

ОСНОВНІ ЕТАПИ NLP

КЛАСИФІКАЦІЯ ТЕКСТУ

Класифікація тексту — це завдання автоматичного віднесення текстового фрагмента до однієї або кількох категорій.

Основні типи класифікації тексту:

1. Бінарна класифікація: спам/не спам, позитивний/негативний відгук
2. Мультикласова класифікація: визначення теми новин (політика, спорт, технології)
3. Мультилейбл класифікація: текст може належати до кількох категорій одночасно

Застосування класифікації тексту:

1. Фільтрація спаму
2. Аналіз тональності
3. Категоризація документів
4. Виявлення теми

ТЕОРЕТИЧНЕ ДОСЛІДЖЕННЯ

ОСНОВНІ ЕТАПИ NLP

РОЗПІЗНАВАННЯ СУТНОСТЕЙ (NAMED
ENTITY RECOGNITION, NER)

Виявлення та класифікація іменованих об'єктів у тексті (Named Entity Recognition, NER) — це задача NLP, що полягає у пошуку згадок важливих сутностей у тексті та визначенні їхнього типу.

Типи сутностей:

1. Особи (PER) — імена людей, історичні постаті, публічні особи.
2. Організації (ORG) — компанії, університети, інституції, урядові структури.
3. Локації (LOC) — країни, міста, географічні об'єкти.
4. Дата/час (DATE) — конкретні дати, роки, часові періоди.
5. Грошові одиниці (MONEY) — валюти, суми, фінансові значення.

Складності NER:

1. Неоднозначність — слова можуть мати кілька значень. Наприклад, Apple як фрукт або як корпорація
2. Вкладені сутності — одна сутність може містити іншу. Наприклад, Національний банк України включає ORG + LOC
3. Нові або рідкісні сутності — моделі складно розпізнати імена чи бренди, яких не було в тренувальних даних.

Застосування NER:

1. Інформаційний пошук — покращення пошукових систем шляхом точнішого розуміння запитів.
2. Витягування знань — автоматичне наповнення баз фактів та онтологій.
3. Аналіз документів — швидке структурування неформатованого тексту (звітів, статей, юридичних документів).
4. Побудова баз знань — формування зв'язків між сутностями, створення графів знань.

КЛЮЧОВІ МОДЕЛІ ДЛЯ NLP

НАЇВНИЙ БАЄСОВИЙ КЛАСИФІКАТОР

Принцип роботи:

1. Заснований на теоремі Баєса, яка дозволяє обчислювати ймовірність належності об'єкта до певного класу.
2. Припускає незалежність ознак (наївне припущення), тобто кожна ознака впливає на результат окремо від інших.
3. Обчислює ймовірність класу на основі сукупності ознак, вибираючи той клас, де ймовірність максимальна.
4. Надзвичайно простий у реалізації та інтерпретації.
5. Швидкий у роботі, добре масштабується на великі набори даних.
6. Ефективний для тексту, особливо коли ознак дуже багато (висока розмірність).

Недоліки:

1. Незалежність ознак — рідко реальна, особливо у тексті, де слова сильно залежать одне від одного.
2. Може давати неточні результати, коли існують складні нелінійні залежності між ознаками.
3. Не враховує порядок слів, контекст та семантику.

Застосування:

1. Фільтрація спаму — один із найвідоміших кейсів.
2. Класифікація текстів — тематичні категорії, теги, рубрикація.
3. Аналіз тональності — визначення позитивного, негативного чи нейтрального настрою.

КЛЮЧОВІ МОДЕЛІ ДЛЯ NLP

ЛОГІСТИЧНА РЕГРЕСІЯ

Принцип роботи:

1. Використовує лінійну модель для розв'язання задачі бінарної класифікації.
2. Застосовує сигмоїдну функцію для перетворення лінійної комбінації ознак у ймовірність (від 0 до 1).
3. Під час навчання мінімізує перехресну ентропію (log-loss), що робить оцінку моделі стабільною та математично обґрунтованою.

Переваги:

1. Швидке навчання та передбачення, підходить для великих датасетів.
2. Висока інтерпретованість: можна зрозуміти вплив кожної ознаки через вагові коефіцієнти.
3. Стійка до перенавчання, особливо при використанні L1/L2 регуляризації.
4. Добре працює, коли дані майже лінійно роздільні.

Недоліки:

1. Не здатна моделювати складні нелінійні залежності без попереднього перетворення ознак.
2. Чутлива до мультиколінеарності, тобто коли ознаки сильно корельовані.
3. Погано працює, якщо кордони між класами дуже складні.

Застосування:

1. Класифікація текстів (спам/не спам, тональність).
2. Оцінка ризиків у фінансах, кредитуванні.
3. Медична діагностика, прогнозування ймовірності захворювання.
4. Маркетинг — передбачення ймовірності покупки або відтоку клієнта.

КЛЮЧОВІ МОДЕЛІ ДЛЯ NLP

LSTM (LONG SHORT-TERM MEMORY)

Принцип роботи:

1. LSTM (Long Short-Term Memory) — це спеціальний тип рекурентних нейронних мереж.
2. Має систему “воріт”, які керують тим, яку інформацію зберегти, а яку — забути.
3. Здатна утримувати довгострокові залежності, що долає проблему «зникаючого градієнта», характерну для класичних RNN.

Ключові компоненти:

1. Ворота забуття (forget gate): визначає, яка інформація втрачається зі стану пам'яті.
2. Вхідні ворота (input gate): контролюють, яка нова інформація додається до стану.
3. Вихідні ворота (output gate): визначають, що саме передати на наступний крок або вивести в результаті.

Переваги:

1. Висока ефективність у роботі з послідовними даними (текст, мова, часові ряди).
2. Можливість зберігати довготривалий контекст у пам'яті.
3. Краще працює з градієнтами, ніж звичайні RNN, завдяки архітектурі воріт.

Недоліки:

1. Повільніше навчання, ніж у простих RNN або сучасних моделей типу Transformer.
2. Великі обчислювальні витрати через складнішу архітектуру.
3. Потребує більш складного налаштування та оптимізації.

Застосування:

1. Машинний переклад (традиційно використовувалась до появи Transformers).
2. Генерація тексту (поезія, автодоповнення, чат-боти).
3. Аналіз тональності (класифікація текстових настроїв).
4. Розпізнавання мови й моделювання аудіопослідовностей.
5. Прогнозування часових рядів (курс валют, погода).

КЛЮЧОВІ МОДЕЛІ ДЛЯ NLP

TRANSFORMERS

Принцип роботи:

1. Архітектура на основі механізму уваги (attention)
2. Паралельна обробка всієї послідовності
3. Не використовує рекурентні зв'язки

Ключові компоненти:

1. Self-Attention: обчислення уваги між усіма словами послідовності
2. Positional Encoding: додавання інформації про позицію слів
3. Feed-Forward Networks: обробка кожного токена окремо

Переваги:

1. Висока паралелізація
2. Ефективне моделювання довгих залежностей
3. State-of-the-art результати в багатьох задачах

Недоліки:

1. Високі вимоги до пам'яті
2. Складність інтерпретації
3. Велика кількість параметрів

Застосування:

1. BERT, GPT, T5 та інші сучасні моделі
2. Машинний переклад
3. Генерація тексту
4. Питання-відповіді

GPT (GENERATIVE PRE-TRAINED TRANSFORMER)

Принцип роботи:

1. Генеративна модель на основі архітектури трансформер
2. Використовує тільки декодерну частину
3. Навчається передбачати наступне слово в послідовності

Еволюція:

1. GPT-1: 117 мільйонів параметрів
2. GPT-2: 1.5 мільярди параметрів
3. GPT-3: 175 мільярдів параметрів
4. GPT-4: ще більша архітектура

Ключові особливості:

1. Багатозадачність: одна модель для різних завдань
2. Few-shot learning: здатність навчатися з кількох прикладів
3. Zero-shot learning: виконання завдань без прикладів

Переваги:

1. Висока якість генерації тексту
2. Універсальність для різних завдань
3. Здатність до few-shot learning

Недоліки:

1. Надзвичайно високі обчислювальні витрати
2. Ризик генерації неточної або упередженої інформації
3. Складність контролю генерації

Застосування:

Генерація тексту, діалогові системи, написання коду та освітні застосування

ПОРІВНЯЛЬНИЙ АНАЛІЗ МЕТОДІВ ВЕКТОРИЗАЦІЇ ТЕКСТУ

Метод	Переваги	Недоліки	Складність реалізації	Застосування в різних задачах	Складність обробки великих обсягів даних
Bag of Words (BOW)	Простий у реалізації, швидка обробка даних, працює з будь-якою мовою	Ігнорує порядок слів у реченні, висока розмірність, часто вимагає додаткової обробки	Низька складність Необхідні технічні знання: базове програмування, робота з рядками, розуміння матриць та векторів	Класифікація текстів, інформаційний пошук (пошук документів, ранжування результатів), аналіз даних та бізнес-застосування (аналіз клієнтських відгуків та обробка звернень)	Середня складність Розмірність росте з розміром словника, важко масштабувати
TF-IDF	Враховує важливість слів, покращує якість моделей та ефективний для пошуку	Ігнорує порядок слів, не враховує семантику та чутливий до шуму	Середня складність Необхідні технічні знання: програмування на Python, робота з бібліотеками, математичні знання та NLP-специфічні знання	Пошукові системи, класифікація текстів, кластеризація документів та рекомендаційні системи	Середня складність Значні обчислення при оновленні індексу, складно для потокових даних
Word2Vec	Зберігає семантичні зв'язки, низька розмірність, архітектурна гнучкість	Потребує великих даних для навчання	Висока складність Необхідні технічні знання: навички роботи з масштабуванням та обробкою великих обсягів даних, програмування на Python, робота з бібліотеками, математичні знання та розуміння векторних операцій	Класифікація текстів, кластеризація документів, аналіз семантичної схожості та тональності, генерація тексту, рекомендаційні системи та вхідні вектори для нейромереж	Висока складність Легко масштабується, підтримує потокове донавчання

ПОРІВНЯЛЬНИЙ АНАЛІЗ МЕТОДІВ ВЕКТОРИЗАЦІЇ ТЕКСТУ

Метод	Переваги	Недоліки	Складність реалізації	Застосування в різних задачах	Складність обробки великих обсягів даних
GloVe (Global Vectors for Word Embeddings)	Ефективне використання даних, використовує глобальну статистику, стабільні та якісні семантичні вектори	Складність оновлення, високі вимоги до пам'яті, потрібно будувати величезну матрицю співзустрічей, неможливо донавчати без повного перенавчання та навчання повільніше, ніж у Word2Vec	Висока складність Необхідні технічні знання: математична база, системні знання, комп'ютерні науки і алгоритми, глибоке навчання та NLP	Семантичні системи високої точності, інформаційний пошук, аналіз значень слів та моделі NLP, де важлива семантика	Середня складність Погано підходить для потокових даних, складно оновлювати

ОГЛЯД ІНСТРУМЕНТІВ ДЛЯ NLP

Інструмент	Основні функції	Підтримка мов	Простота використання	Приклади можливих застосувань NLP в різних галузях
NLTK	Токенізація, стемінг/лемматизація, POS-тегінг, граматика, класичні NLP-корпуси і навчальні приклади, інструменти для навчання моделей (Naive Bayes, MaxEnt)	Багатомовна (через корпуси і словники), але залежить від доступних ресурсів для конкретної мови	Добре для навчання — дуже багато прикладів, академічна документація; API може бути «низькорівневим»	Класичний навчальний набір; ідеальний для освітніх цілей, прототипів і експериментів з базовими методами
spaCy	Швидке та оптимізоване NLP: токенізація, лемматизація, POS, NER, залежності (dependency parsing), вектори слів; pipeline-архітектура	Модельна підтримка для багатьох мов залежно від моделей/пакетів	Висока — сучасне, чітке API; легко інтегрується в продукти	Промислова швидкість і стиль; добре підходить для production-завдань і інтеграції в пайплайни; має вбудовані вектори і підтримку кастомних компонентів

ОГЛЯД ІНСТРУМЕНТІВ ДЛЯ NLP

Інструмент	Основні функції	Підтримка мов	Простота використання	Особливості / коли використовувати
Hugging Face Transformers	Передтреновані трансформери (BERT, GPT, T5, RoBERTa та ін.), токенайзери, fine-tuning, інфраструктура для inference	Широка — моделі для багатьох мов; мультимовні моделі (mBERT, XLM-R)	Середня–висока: використання готових моделей просте, але робота з великими моделями вимагає ресурсів	Сильний в NLP-SOTA задачах (QA, класифікація, генерація тексту); екосистема hub з тисячами моделей; підходить для задач, де важлива якість і transfer learning
Gensim	Тренування/завантаження векторних представлень (Word2Vec, Doc2Vec), тематичне моделювання (LDA), обробка великих корпусів у потоковому режимі	Мовонезалежна (робота з текстом на будь-якій мові)	Добре — API зрозуміле для векторних задач і тематики; оптимізований для великих даних	Сильний у тематичному моделюванні та побудові векторів/знаходженні схожості; ефективний з великими корпусами та streaming

ДЯКУЮ ЗА УВАГУ!
